

CLASIFICACIÓN DE PREFERENCIAS HUMANAS EN RESPUESTAS DE CHATBOTS LLM

Diego Alejandro Vásquez-Aguilar

Fundamentos de Deep Learning 2026-02

1. Contexto de aplicación

Los grandes modelos de lenguaje (LLMs en inglés) se usan cada vez más como asistentes conversacionales. Sin embargo, ante una misma pregunta, distintos modelos pueden generar respuestas igualmente válidas, pero con diferencias en la calidad percibida y en el nivel de satisfacción de las personas usuarias. Plataformas como *Chatbot Arena* (parte de The Large Model Systems Organization [LMSYS]) enfrentan a dos LLMs anónimos ante el mismo prompt y registran cuál respuesta prefiere cada usuario. Este tipo de datos de preferencia humana es la base de técnicas como RLHF (*Reinforcement Learning from Human Feedback*), donde se entrena un “modelo de recompensa” que aprende a imitar el juicio humano y guía el ajuste (finetuning) de LLMs hacia respuestas más alineadas con lo que las personas realmente prefieren.

Usar directamente un LLM como juez de otras respuestas es una alternativa interesante para su exploración, pero la literatura [2] ha identificado sesgos sistemáticos en ese enfoque: sesgo de posición (favorecer la primera respuesta mostrada), sesgo de verbosidad (favorecer respuestas más largas) y sesgo de auto-mejora (un modelo favoreciendo respuestas generadas por modelos de su misma familia). Por ello, entrenar un modelo de preferencia específico y validado empíricamente con datos humanos reales sigue siendo un objeto de estudio relevante y es el problema que aborda este proyecto académico, replicando la competencia de Kaggle “LLM Classification Finetuning”[1].

2. Objetivo de machine learning

Se busca predecir cuál de dos respuestas generadas por LLMs (A o B) preferirá un usuario de chatbot o si declarará un empate **dada la siguiente información de entrada**: el prompt (o conversación de uno o varios turnos) planteado por el usuario, y el texto completo de las dos respuestas generadas por los dos modelos en competencia (sin revelar la identidad de los modelos).

Formalmente, es un problema de **clasificación multiclase supervisado** (3 clases): dados (prompt, response_a, response_b), el modelo debe producir una distribución de probabilidad sobre las clases {gana A, gana B, empate}.

3. Dataset

Característica	Detalle
Tipo de datos	Datos tabulares con campos de texto libre (prompt y respuestas de dos LLMs) en un CSV. Columnas de <code>train.csv</code> : <code>id</code> , <code>model_a</code> , <code>model_b</code> , <code>prompt</code> , <code>response_a</code> , <code>response_b</code> , <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code> . En <code>test.csv</code> se retiran <code>model_a/model_b</code> y las columnas <code>winner_*</code> , que son justamente lo que hay que predecir.
Tamaño (registros)	<code>train.csv</code> contiene 57.477 filas. El test set oculto de la competencia tiene aprox. 25.000 filas.
Tamaño en disco	<code>train.csv</code> ocupa 179.858 KB (~175.6 MB) .
Cobertura de modelos	64 LLMs distintos observados en el dataset completo (top: <code>gpt-4-1106-preview</code> , <code>gpt-3.5-turbo-0613</code> , <code>gpt-4-0613</code> , <code>claude-2.1</code> , <code>claude-instant-1</code>). Cada fila enfrenta a dos modelos distintos elegidos al azar por la plataforma, por lo que <code>model_a</code> y <code>model_b</code> cambian de fila a fila.
Variable objetivo	Tres columnas binarias mutuamente excluyentes que indican la selección del usuario: <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code>
Otros archivos	<code>test.csv</code> (<code>id</code> , <code>prompt</code> , <code>response_a</code> , <code>response_b</code>) y <code>sample_submission.csv</code> (<code>id</code> , <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code>).

Distribución de clases

Conviene separar dos preguntas distintas que suelen confundirse aquí. **model_a** y **model_b** NO son categorías fijas: son etiquetas de posición que rotan de fila a fila entre 64 LLMs observados (un mismo modelo puede aparecer como A en una fila y como B en otra), así que no tiene sentido interpretar la frecuencia de “gana A” vs. “gana B” como “qué modelo es mejor”.

(a) **Balance de la variable objetivo y sesgo de posición** — resultados del análisis exploratorio sobre el dataset completo ($n=57.477$). La distribución observada de la etiqueta objetivo es: **gana_A 34.91 %**, **gana_B 34.19 %**, **empate 30.90 %** — razonablemente balanceada entre las tres clases, con una leve subrepresentación del empate. Sobre el sesgo de posición: excluyendo empates, $P(\text{gana A}) = 0.505$ y $P(\text{gana B}) = 0.495$ (diferencia de solo 0.010), por lo que **no se observa evidencia de sesgo de posición**: los usuarios de chatbot no favorecen sistemáticamente la primera respuesta mostrada en este dataset.




Figura 1: Distribución de las clases de la variable objetivo.

(b) **Sesgo de verbosidad** — **sí se observa un patrón consistente**. A diferencia del sesgo de posición, la longitud de las respuestas sí muestra una asociación clara con el resultado: cuando gana A, la respuesta A promedia 1.568 caracteres frente a 1.314 de B ($\sim 19\%$ más larga); cuando gana B, la respuesta B promedia 1.569 caracteres frente a 1.291 de A ($\sim 22\%$ más larga). En ambos sentidos, **la respuesta ganadora es en promedio $\sim 20\%$ más larga que la perdedora**. Esto no prueba causalidad puesto que una respuesta más completa puede simplemente ser mejor, pero es la correlación de verbosidad mencionada previamente [2] y se tratará como posible feature/confusor durante el modelado.




Figura 2: Relación entre la longitud de las respuestas y frecuencia en la preferencia.

(c) **Calidad relativa entre modelos (análisis complementario)**. Reagrupando las victorias por identidad real del modelo (uniendo sus apariciones como A y como B, con un mínimo de 30 apariciones), los modelos con mayor tasa de victorias observada son **gpt-4-1106-preview (55.1 %)** y **gpt-3.5-turbo-0314 (54.6 %)**, con una dispersión de casi 20 puntos porcentuales frente a los modelos del final del top-15.




Figura 3: Total de victorias observadas por modelo, considerando sus apariciones como A y B.

Notas de calidad de datos

No se encontraron valores nulos ni filas duplicadas exactas; se identificaron 275 filas donde `response_a` es idéntica a `response_b`, estos casos límite se revisarán antes de la fase de entrenamiento. La longitud de respuesta tiene una mediana de 1.081 caracteres y un máximo de 54.058, por lo que se explorará definir una estrategia de truncado para el modelado.

4. Métricas de desempeño

Tipo	Métrica y justificación
Machine Learning (principal)	Log Loss multiclase (3 clases). Es la métrica oficial de la competencia: penaliza con fuerza las predicciones confiadas e incorrectas, lo cual es deseable en un modelo de recompensa que alimentará decisiones automatizadas.
Machine Learning (secundarias)	Accuracy y F1-macro (para comunicar resultados de forma más interpretable) y matriz de confusión para analizar el desbalance entre clases, especialmente la clase “empate”.
Negocio	(1) Tasa de acuerdo entre el modelo de preferencia y evaluadores humanos, como proxy de confiabilidad para reemplazar/asistir evaluación humana costosa; (2) reducción de costo y tiempo de evaluación humana (horas-persona ahorradas) al automatizar comparaciones A/B de modelos; (3) calidad percibida del sistema final (engagement o satisfacción) cuando el modelo de recompensa se usa para afinar un LLM vía RLHF.

5. Antecedentes y resultados previos

El problema abordado en este proyecto corresponde a la tarea propuesta en la competencia de Kaggle “LLM Classification Finetuning” [1], cuyo objetivo es predecir la preferencia humana entre dos respuestas generadas por modelos de lenguaje. La competencia todavía activa ofrece un fondo de premios de USD 100.000 y registra cerca de 1.850 equipos participantes.

Como referencia para la evaluación, **una predicción que asigna equiprobabilidades a las tres clases** obtiene un Log Loss de $\ln(3) \approx 1,10$. Por tanto, este valor constituye una línea base frente a la cual pueden compararse los modelos desarrollados, siendo mejores los resultados con valores de Log Loss inferiores.

Hasta la fecha las soluciones con mejor desempeño en la competencia emplearon principalmente modelos de lenguaje de tamaño mediano, como variantes de Gemma 2 y Llama 3, ajustados mediante *fine-tuning* para la tarea de clasificación. Además, algunas soluciones incorporaron pseudo-etiquetado, datos adicionales de Chatbot Arena y ensamblado de modelos. Estas estrategias permitieron obtener valores de Log Loss cercanos a 0,83.

Como antecedente del proceso de generación y evaluación de los datos, [2] presenta Chatbot Arena, una plataforma que recopila comparaciones entre respuestas de diferentes LLMs a partir de preferencias humanas. Este trabajo también identifica diversos sesgos que pueden afectar dichas evaluaciones, entre ellos los asociados con la posición de las respuestas, la verbosidad y la auto-mejora, previamente discutidos en el contexto del dataset. Estos aspectos son relevantes para interpretar los datos utilizados en el presente proyecto y establecer sus limitaciones.

Referencias

- [1] W.-L. Chiang, L. Zheng, L. Dunlap, J. E. Gonzalez, I. Stoica, P. Mooney, S. Dane, A. Howard, and N. Keating, “LLM Classification Finetuning,” Kaggle, 2024. [Online]. Available: <https://www.kaggle.com/competitions/llm-classification-finetuning>
- [2] W.-L. Chiang, L. Zheng, Y. Sheng, A. N. Angelopoulos, T. Li, D. Li, B. Zhu, H. Zhang, M. I. Jordan, J. E. Gonzalez, and I. Stoica, “Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference,” in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, vol. 235, pp. 8359–8388, 2024.