

CLASIFICACIÓN DE PREFERENCIAS HUMANAS EN RESPUESTAS DE CHATBOTS LLM

Diego Alejandro Vásquez-Aguilar

Fundamentos de Deep Learning 2026-02

1. Contexto de aplicación

Los grandes modelos de lenguaje (LLMs en inglés) se usan cada vez más como asistentes conversacionales, pero dos modelos distintos pueden responder la misma pregunta de formas válidas y aun así generar niveles muy distintos de satisfacción en las personas usuarias. Plataformas como *Chatbot Arena* (parte de The Large Model Systems Organization [LMSYS]) enfrentan a dos LLMs anónimos ante el mismo prompt y registran cuál respuesta prefiere cada usuario. Este tipo de datos de preferencia humana es la base de técnicas como RLHF (*Reinforcement Learning from Human Feedback*), donde se entrena un “modelo de recompensa” que aprende a imitar el juicio humano y guía el ajuste (finetuning) de LLMs hacia respuestas más alineadas con lo que las personas realmente prefieren.

Usar directamente un LLM como juez de otras respuestas es una alternativa interesante para su exploración, pero la literatura ha identificado sesgos sistemáticos en ese enfoque: sesgo de posición (favorecer la primera respuesta mostrada), sesgo de verbosidad (favorecer respuestas más largas) y sesgo de auto-mejora (un modelo favoreciendo respuestas de su misma familia). Por ello, entrenar un modelo de preferencia específico y validado empíricamente con datos humanos reales sigue siendo un objeto de estudio relevante y es el problema que aborda este proyecto académico, replicando la competencia de Kaggle “LLM Classification Finetuning” (basada en datos de Chatbot Arena de LMSYS).

2. Objetivo de machine learning

Queremos predecir cuál de dos respuestas generadas por LLMs (respuesta A o respuesta B) preferirá un usuario de chatbot o si declarará un empate **dada la siguiente información de entrada:** el prompt (o conversación de uno o varios turnos) planteado por el usuario, y el texto completo de las dos respuestas generadas por los dos modelos en competencia (sin revelar la identidad de los modelos).

Formalmente, es un problema de **clasificación multiclase supervisado** (3 clases): dado el par (prompt, response_a, response_b), el modelo debe producir una distribución de probabilidad sobre las clases {gana A, gana B, empate}.

3. Dataset

Característica	Detalle
Fuente	Kaggle – “LLM Classification Finetuning” (basada en datos de Chatbot Arena, LMSYS)
Tipo de datos	Datos tabulares con campos de texto libre (prompt y respuestas de dos LLMs) en un CSV. Columnas de <code>train.csv</code> : <code>id</code> , <code>model_a</code> , <code>model_b</code> , <code>prompt</code> , <code>response_a</code> , <code>response_b</code> , <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code> . En <code>test.csv</code> se retiran <code>model_a/model_b</code> y las columnas <code>winner_*</code> , que son justamente lo que hay que predecir.
Tamaño (registros)	<code>train.csv</code> contiene 57.477 filas. El test set oculto de la competencia tiene aprox. 25.000 filas.
Tamaño en disco	<code>train.csv</code> ocupa 179.858 KB (~175.6 MB) .
Cobertura de modelos	64 LLMs distintos observados en el dataset completo (top: <code>gpt-4-1106-preview</code> , <code>gpt-3.5-turbo-0613</code> , <code>gpt-4-0613</code> , <code>claude-2.1</code> , <code>claude-instant-1</code>). Cada fila enfrenta a dos modelos distintos elegidos al azar por la plataforma, por lo que <code>model_a</code> y <code>model_b</code> cambian de fila a fila.
Variable objetivo	Tres columnas binarias mutuamente excluyentes que indican la selección del juez: <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code>
Otros archivos	<code>test.csv</code> (<code>id</code> , <code>prompt</code> , <code>response_a</code> , <code>response_b</code>) y <code>sample_submission.csv</code> (<code>id</code> , <code>winner_model_a</code> , <code>winner_model_b</code> , <code>winner_tie</code>).

Distribución de clases

Conviene separar dos preguntas distintas que suelen confundirse aquí. **model_a** y **model_b** NO son categorías fijas: son etiquetas de posición que rotan de fila a fila entre 64 LLMs observados (un mismo modelo puede aparecer como A en una fila y como B en otra), así que no tiene sentido interpretar la frecuencia de “gana A” vs. “gana B” como “qué modelo es mejor”.

(a) Balance de la variable objetivo y sesgo de posición — resultados del análisis exploratorio sobre el

dataset completo (n=57.477). La distribución observada de la etiqueta objetivo es: **gana_A 34.91 %, gana_B 34.19 %, empate 30.90 %** — razonablemente balanceada entre las tres clases, con una leve subrepresentación del empate. Sobre el sesgo de posición: excluyendo empates, $P(\text{gana A}) = 0.505$ y $P(\text{gana B}) = 0.495$ (diferencia de solo 0.010), por lo que **no se observa evidencia de sesgo de posición**: los usuarios de chatbot no favorecen sistemáticamente la primera respuesta mostrada en este dataset.




Figura 1: Distribución de las clases de la variable objetivo.

(b) Sesgo de verbosidad — sí se observa un patrón consistente. A diferencia del sesgo de posición, la longitud de las respuestas sí muestra una asociación clara con el resultado: cuando gana A, la respuesta A promedia 1.568 caracteres frente a 1.314 de B ($\sim 19\%$ más larga); cuando gana B, la respuesta B promedia 1.569 caracteres frente a 1.291 de A ($\sim 22\%$ más larga). En ambos sentidos, **la respuesta ganadora es en promedio $\sim 20\%$ más larga que la perdedora**. Esto no prueba causalidad (una respuesta más completa puede simplemente ser mejor), pero es la correlación de verbosidad descrita en el enunciado del problema y se tratará como posible feature/confusor durante el modelado.




Figura 2: Relación entre la longitud de las respuestas y frecuencia en la preferencia.

(c) Calidad relativa entre modelos (análisis complementario). Reagrupando las victorias por identidad real del modelo (uniendo sus apariciones como A y como B, con un mínimo de 30 apariciones), los modelos con mayor tasa de victorias observada son **gpt-4-1106-preview (55.1 %)** y **gpt-3.5-turbo-0314 (54.6 %)**, con una dispersión de casi 20 puntos porcentuales frente a los modelos del final del top-15.




Figura 3: Total de victorias observadas por modelo, considerando sus apariciones como A y B.

Notas de calidad de datos

No se encontraron valores nulos ni filas duplicadas exactas; se identificaron 275 filas donde **response_a** es idéntica a **response_b**, estos casos límite se revisarán antes de la fase de entrenamiento. La longitud de respuesta tiene una mediana de 1.081 caracteres y un máximo de 54.058, por lo que se explorará definir una estrategia de truncado para el modelado.

4. Métricas de desempeño

Tipo	Métrica y justificación
Machine Learning (principal)	Log Loss multiclase (3 clases). Es la métrica oficial de la competencia: penaliza con fuerza las predicciones confiadas e incorrectas, lo cual es deseable en un modelo de recompensa que alimentará decisiones automatizadas.
Machine Learning (secundarias)	Accuracy y F1-macro (para comunicar resultados de forma más interpretable) y matriz de confusión para analizar el desbalance entre clases, especialmente la clase “empate”.
Negocio	(1) Tasa de acuerdo entre el modelo de preferencia y evaluadores humanos, como proxy de confiabilidad para reemplazar/asistir evaluación humana costosa; (2) reducción de costo y tiempo de evaluación humana (horas-persona ahorradas) al automatizar comparaciones A/B de modelos; (3) calidad percibida del sistema final (engagement o satisfacción) cuando el modelo de recompensa se usa para afinar un LLM vía RLHF.

5. Referencias y resultados previos

El problema replica la competencia pública (y todavía activa) de Kaggle: “LLM Classification Finetuning” (Chiang et al., 2024), con un fondo de premios de USD 100.000 y cerca de 1.850 equipos participantes.

Línea base: un modelo que asigna probabilidad uniforme a las 3 clases obtiene un Log Loss de $\ln(3) \approx 1,09$, que sirve como punto de referencia mínimo a superar.

Soluciones destacadas de la competencia: los equipos mejor ubicados combinaron el ajuste fino (*fine-tuning*) de LLMs de tamaño mediano (p. ej. variantes de Gemma 2 y Llama 3) como clasificadores de secuencias, junto con técnicas de pseudo-etiquetado, datos externos deduplicados (~33k ejemplos adicionales de Chatbot Arena) y ensamblado de modelos, alcanzando valores de Log Losses sustancialmente por debajo de la línea base uniforme ($\approx 0,83$).

Fundamento teórico: Chiang et al. (2024), “Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference”, describe la plataforma de origen de los datos y discute los sesgos de evaluación (posición, verbosidad, auto-mejora) mencionados en la sección de contexto.

Fuente del dataset: Wei-Lin Chiang, Lianmin Zheng, Lisa Dunlap, Joseph E. Gonzalez, Ion Stoica, Paul Mooney, Sohler Dane, Addison Howard, and Nate Keating. *LLM Classification Finetuning*. <https://kaggle.com/competitions/llm-classification-finetuning>, 2024. Kaggle.